LAPORAN PRAKTIKUM WEB SCRAPING

Topik: Academic Publication Collector

Program Studi : Teknik Informatika
Universitas : Universitas Pelita Bangsa

1. Tujuan dan Latar Belakang Praktikum

Praktikum ini bertujuan untuk mengimplementasikan teknik ekstraksi data (web scraping) menggunakan bahasa pemrograman Python. Proyek yang dipilih adalah "Academic Publication Collector", di mana program dirancang untuk mengumpulkan metadata publikasi ilmiah yang meliputi judul artikel, nama penulis, tanggal publikasi, dan tautan (URL) artikel.

Selain memenuhi kompetensi dasar ekstraksi data menggunakan pustaka requests dan BeautifulSoup, program ini juga dirancang untuk mengintegrasikan berbagai materi fundamental, seperti penggunaan Regular Expressions (Regex) untuk validasi dan pembersihan data, Command Line Interface (CLI) menggunakan argparse untuk fleksibilitas pencarian, serta manajemen file dinamis (penyimpanan ke format CSV dan backup otomatis menggunakan ZIP).

2. Pemilihan Target Website dan Argumentasi Logis

Target utama dari scraping ini adalah portal jurnal internal kampus, yaitu Jurnal Pelita Bangsa (khususnya Jurnal SIGMA). Pemilihan website ini didasarkan pada beberapa pertimbangan akademis dan teknis yang rasional:

- **Relevansi Akademik dan Kepemilikan Data:** Melakukan scraping pada repositori jurnal kampus sendiri memberikan nilai tambah yang signifikan. Data yang dihasilkan tidak hanya sekadar 'data acak' dari internet, melainkan dataset nyata yang merepresentasikan rekam jejak publikasi riset di lingkungan Universitas Pelita Bangsa. Hal ini menunjukkan inisiatif untuk memanfaatkan teknologi dalam mengenali ekosistem akademik sendiri.
- **Kesesuaian Arsitektur (Open Journal Systems / OJS):** Portal jurnal akademik mayoritas menggunakan platform OJS. Secara teknis, sistem OJS menyajikan struktur HTML yang statis dan sangat terstruktur (seperti adanya class 'title', 'authors', dan 'published'). Hal ini sangat ideal untuk penerapan library BeautifulSoup, memungkinkan program berjalan stabil tanpa terhalang oleh proses rendering JavaScript yang berat seperti pada portal berita komersial.
- **Menghindari Pelanggaran Etika dan Sistem Anti-Bot:** Banyak mahasiswa cenderung memilih target raksasa seperti Google Scholar atau ResearchGate. Namun, sistem tersebut dilindungi oleh proteksi anti-scraping tingkat tinggi (seperti Cloudflare dan Captcha) yang bertujuan mencegah serangan DDoS. Memaksakan scraping pada web tersebut berisiko

pemblokiran IP dan melanggar etika ekstraksi data. Menggunakan portal OJS kampus yang bersifat open-access memberikan lingkungan yang jauh lebih aman (minim risiko blokir) dan legal untuk tujuan edukasi.

- **Efisiensi Parameter HTTP GET:** Dalam sistem OJS, fitur pencarian berjalan menggunakan metode HTTP GET standar tanpa memerlukan token keamanan dinamis (seperti CSRF Token) untuk sekadar membaca data publik. Hal ini memungkinkan integrasi yang sangat mulus dengan modul argparse di terminal, sehingga user dapat mengganti-ganti kata kunci pencarian (query) langsung dari Command Line tanpa mengubah source code.

3. Pemenuhan Persyaratan Implementasi

Program ini telah memenuhi seluruh indikator yang disyaratkan dalam praktikum, antara lain:

- Pengambilan minimal 30 record publikasi terkait kata kunci yang dimasukkan pengguna.
- Implementasi dua pola Regex: (1) Membersihkan spasi berlebih pada teks HTML, dan (2) Mengekstrak format tanggal spesifik (YYYY-MM-DD) dari string metadata OJS.
- Penyimpanan dataset akhir ke dalam format terstruktur (.csv).
- Pembuatan folder output secara otomatis (menggunakan pathlib) dan pengarsipan hasil ke format .zip (menggunakan shutil).
- Penerapan argumen CLI (seperti --url, --keyword, --limit, dan --backup).
- Mekanisme penanganan error (try-except) untuk koneksi internet, pencegahan kegagalan saat data kosong, dan penyaringan (filtering) ketat agar hasil sesuai dengan keyword.

4. Kesimpulan

Melalui pemilihan portal jurnal OJS kampus sebagai objek ekstraksi, praktikum ini tidak hanya berhasil memenuhi tantangan pemrograman Python secara teknis, tetapi juga menunjukkan cara berpikir taktis dalam menghindari batasan sistem anti-bot. Solusi ini menghasilkan dataset yang bersih, relevan secara akademis, dan siap digunakan untuk analisis lebih lanjut.